



Modelos de Predição Aplicados no Diagnóstico do AVC: Uma Revisão de Escopo

Prediction Models Applied in Stroke Diagnosis: a Scope Review

Modelos de Predicción Aplicados en el Diagnóstico de Ictus: una Revisión del Alcance

Maria Adriana Ferreira da Silva¹, Angélica Félix de Castro², Isaac de Lima Oliveira Filho³

RESUMO

Objetivo: Neste artigo, é apresentada uma revisão de escopo com o objetivo de identificar modelos de predição aplicados no diagnóstico do Acidente Vascular Cerebral (AVC). **Método:** A RE foi realizada em cinco fontes de busca, utilizando uma *string* de busca e critérios de inclusão e exclusão. **Resultados:** Após a realização das etapas definidas no protocolo, 615 trabalhos foram retornados na primeira etapa, destes apenas 9 foram selecionados para serem analisados e terem suas informações extraídas. **Conclusão:** Mediante os resultados apresentados, foi possível identificar que a maioria dos trabalhos desenvolveram modelos de aprendizagem, seguido da comparação de algoritmos e criação de algoritmos. Com relação aos recursos, os mais utilizados foram: linguagem de programação Python e biblioteca *scikit-learn*. Com relação aos modelos e algoritmos mais utilizados estão: Árvore de decisão, *Naive Bayes*, *Random Forest* e KNN (*K-Nearest Neighbors*). A maioria dos trabalhos analisados utilizaram as métricas *Recall*, Precisão, F1-Score e Acurácia para validarem as soluções. Dentre as limitações identificadas, destacam-se aquelas relacionadas à avaliação do desempenho das soluções propostas e à ausência de aspectos relevantes para os estudos analisados.

Descritores: AVC, Modelos de predição, Revisão de Escopo

ABSTRACT

Objective: In this article, a scope review is presented with the objective of identifying prediction models applied in the diagnosis of Cerebral Vascular Accident (CVA). **Method:** RE was performed on five search sources, using a search string and inclusion and exclusion criteria. **Results:** After carrying out the steps defined in the protocol, 615 papers were returned in the first step, of which only 9 were selected to be analyzed and have their information extracted. **Conclusion:** Through the results presented, it was possible to identify that most of the works developed learning models, followed by the comparison of algorithms and creation of algorithms. Regarding the resources used, the most used were: Python programming language and *scikit-learn* library. The most used models and algorithms are: Decision tree, *Naive Bayes*, *Random Forest* and KNN (*K-Nearest Neighbors*). Most of the works analyzed used the metrics *Recall*, Precision, F1-Score and Accuracy to validate the solutions. Among the identified limitations, those related to the evaluation of the performance of the proposed solutions and the absence of relevant aspects for the analyzed studies stand out.

Keywords: CVA, Prediction models, Scope Review

RESUMEN

Objetivo: En este artículo se presenta una revisión de alcance con el objetivo de identificar modelos de predicción aplicados en el diagnóstico del Accidente Vascular Cerebral (ACV). **Método:** RE se realizó en cinco fuentes de búsqueda, utilizando una cadena de búsqueda y criterios de inclusión y exclusión. **Resultados:** Después de realizar los pasos definidos en el protocolo, en el primer paso se devolvieron 615 artículos, de los cuales solo 9 fueron seleccionados para ser analizados y extraer su información. **Conclusión:** A través de los resultados presentados, fue posible identificar que la mayoría de los trabajos desarrollaron modelos de aprendizaje, seguidos por la comparación de algoritmos y la creación de algoritmos. En cuanto a los recursos utilizados, los más utilizados fueron: lenguaje de programación Python y biblioteca *scikit-learn*. Los modelos y algoritmos más utilizados son: Árbol de decisión, *Naive Bayes*, *Random Forest* y KNN (*K-Nearest Neighbors*). La mayoría de los trabajos analizados utilizaron las métricas *Recall*, Precision, F1-Score y Accuracy para validar las soluciones. Entre las limitaciones identificadas destacan las relacionadas con la evaluación del desempeño de las soluciones propuestas y la ausencia de aspectos relevantes para los estudios analizados.

Descriptores: ACV, Modelos de predicción, Revisión del alcance

¹Engenheira de Software, Universidade Federal Rural do Semi-Árido – UFERSA, Pau dos Ferros (RN), Brasil e Discente do Programa de Pós-Graduação em Ciência da Computação - PPgCC, Universidade Federal Rural do Semi-Árido - UFERSA e Universidade do Estado do Rio Grande do Norte - UERN, Mossoró (RN), Brasil.

²Professora Associada do Departamento de Computação, Universidade Federal Rural do Semi-Árido - UFERSA, Mossoró (RN), Brasil.

³Professor Efetivo do Departamento de Informática, Universidade do Estado do Rio Grande do Norte – UERN, Mossoró (RN), Brasil.

INTRODUÇÃO

O Acidente Vascular Cerebral (AVC), pode ser definido como uma alteração do fluxo de sangue no cérebro e pode ser classificado em três tipos: Acidente Vascular Cerebral Isquêmico (AVCi), Acidente Vascular Cerebral Hemorrágico (AVCh) e Ataque Isquêmico Transitório (AIT), sendo o AVC Isquêmico o tipo mais comum. Dados atuais indicam que o AVC é responsável por uma das principais taxas de mortalidade e incapacidade em escala global⁽¹⁾.

Em sua fase inicial, o AVC pode manifestar sinais indicativos antes mesmo de sua ocorrência. Os sinais que ocorrem com maior frequência são: confusão mental, dificuldade para falar ou compreender, dormência em apenas um lado do corpo e outros. A identificação precoce desses sinais é de extrema importância, pois uma lesão muito grave pode causar morte instantânea do paciente ou deixar deficiências que podem afetar significativamente sua vida⁽²⁾. Além disso, essa identificação precoce, permite o início imediato do acompanhamento do paciente antes da ocorrência do AVC, resultando na diminuição das sequelas e contribuindo para a prevenção do AVC⁽¹⁾.

Conhecer os fatores de risco do AVC também é fundamental para prevenir a sua ocorrência e consequentemente reduzir os custos que possam vir em reabilitação e hospitalização⁽²⁾. Os fatores de maior influência para o AVC são: hipertensão, sexo, diabetes, tabagismo, sedentarismo, histórico de AVC na família, idade e raça⁽³⁾. Estimativas apontam que uma em cada seis pessoas ao redor do mundo podem enfrentar um AVC em qualquer fase da vida. Tais dados mostram a necessidade de desenvolver soluções voltadas para a melhoria do ponto de vista da saúde e bem-estar dessas pessoas, principalmente no que diz respeito à reabilitação, prevenção e diagnóstico de doenças⁽²⁾.

Na literatura, diversas soluções vêm sendo desenvolvidas com o objetivo de auxiliar no diagnóstico do AVC, utilizando técnicas de inteligência artificial. O trabalho de⁽⁴⁾, por exemplo, descreve o uso de aprendizado de máquina e ressonância magnética para ajudar no diagnóstico de distúrbios cerebrais. O objetivo principal dessas soluções é ajudar os profissionais da saúde a fazerem previsões clínicas com maior precisão. Essas soluções têm o potencial de agilizar o diagnóstico precoce do AVC e permitir a implementação imediata de tratamentos, contribuindo para aprimorar a saúde e o bem-estar dos pacientes. No entanto, o diagnóstico do AVC, especialmente por meio de exames de imagem, pode ser caro e difícil de ser realizado⁽⁵⁾.

Neste caso, o reconhecimento precoce desses sinais e fatores de risco do AVC facilita no atendimento inicial e se torna vital para a identificação de complicações que venham a acontecer⁽²⁾. Também se constata que para controlar tais fatores de risco e sinais indicativos, faz-se necessário a adoção de hábitos saudáveis de modo que

previnam os problemas causados individualmente por cada fator de risco⁽²⁾. Além disso, é necessário o desenvolvimento de ferramentas para ajudar o médico em um diagnóstico mais rápido de modo a auxiliá-lo em decisões mais assertivas⁽⁶⁾.

Diante da necessidade de aprimorar as estratégias de prevenção do AVC, o objetivo deste trabalho é identificar, por meio de uma Revisão de Escopo (RE), soluções preditivas presentes na literatura que façam uso de algoritmos de aprendizado de máquina para auxiliar na prevenção do AVC antes mesmo de sua ocorrência. Para tal, a seguinte questão de pesquisa foi definida: “Quais soluções disponíveis na literatura são utilizadas para atuar na prevenção e diagnóstico do AVC?”.

METODOLOGIA DA PESQUISA

A metodologia deste estudo é baseada em uma RE, que tem como objetivo mapear os principais conceitos de uma determinada área de conhecimento, por meio de uma análise de trabalhos já publicados⁽⁷⁾. Nessa perspectiva, esta RE utilizou os procedimentos metodológicos apresentados em⁽⁷⁾, com retificações apresentadas por⁽⁸⁻⁹⁾. Adaptando aos propósitos desta pesquisa, a estrutura desta revisão consiste nas seguintes etapas: 1) apresentação da questão e objetivo de pesquisa; 2) identificação de estudos relevantes a temática dessa pesquisa; 3) seleção de estudo, de acordo com os critérios predefinidos; 4) representação dos dados; 5) avaliação e extração dos resultados; e 6) apresentação dos resultados.

Questões de Pesquisa

Inicialmente, foi definida a seguinte Questão de Pesquisa (QPE): “**Quais soluções disponíveis na literatura são utilizadas para atuar na prevenção e diagnóstico do AVC?**”. Para responder este questionamento, foram elaboradas quatro Questões Específicas (QE):

- **QE1:** Quais as principais soluções?
- **QE2:** Quais recursos tecnológicos utilizados para o desenvolvimento dessas soluções?
- **QE3:** Quais as limitações identificadas no trabalho?
- **QE4:** Como foi realizada a validação dessas soluções?

Escopo

O escopo desta pesquisa está voltado para estudos que apresentem estratégias baseadas em aprendizado de máquina e aplicadas ao diagnóstico do AVC. Assim, pode-se identificar os algoritmos, linguagens, ferramentas utilizadas no desenvolvimento dessas estratégias, como essas soluções foram validadas e quais as limitações apresentadas.

Estratégia de Busca

Esta RE teve por objetivo encontrar estudos publicados entre 2016 e 2021, e escritos no idioma inglês, considerando a sua utilização na maioria das conferências, revistas e periódicos de relevância para a área tecnológica. A busca foi realizada em cinco fontes de busca relevantes na área, a citar: [ACM Digital Library¹](#), [IEEE Xplore²](#), [MedLine³](#), [Scopus⁴](#), [Web of Science⁵](#). Essas fontes foram selecionadas com base na disponibilidade em acessar o conteúdo dos artigos e por apresentarem uma grande quantidade de publicações na área da saúde.

Na sequência, definiu-se a seguinte string de busca: (“Stroke” OR “Hemorrhagic Stroke” OR “Ischemic Stroke”) AND (“Machine Learning” OR “Artificial Intelligence” OR “Deep Learning”) AND (“Algorithm” OR “Platform” OR “Application”) AND (“Decision tree” OR “Support Vector Machine” OR “K-closest neighbors” OR “Multi Layer Perceptron” OR “Ensemble”).

Critérios para seleção e avaliação

Para a selecionar os estudos de maior relevância, foram definidos Critérios de Inclusão (CI) e Critérios de Exclusão (CE), a citar:

Critérios de Inclusão:

- CI1) Estudos com foco na pesquisa;
- CI2) Estudos publicados entre os anos de 2016 e 2021;
- CI3) Estudos publicados no idioma Inglês;
- CI4) Estudos que utilizaram algoritmo de Aprendizagem de Máquina (AM) para desenvolvimento de soluções.

Critérios de Exclusão:

- CE1) Estudos que não apresentam informações suficientes para responder a nenhuma das questões de pesquisa;
- CE2) Estudos que não possibilitem download do arquivo completo de forma gratuita;
- CE3) Estudos repetidos nas fontes de busca.

SELEÇÃO DOS TRABALHOS

O processo de seleção e escolha dos trabalhos foi dividido em quatro etapas. A Etapa I consistiu na pré-seleção dos artigos a partir da aplicação das strings de busca nas fontes de dados juntamente com a leitura do título e palavras-chaves. Nessa etapa fez-se a verificação dos critérios de inclusão CI2 e CI3. Ao final, 615 trabalhos foram selecionados.

Na Etapa II o título, as palavras-chaves e os resumos dos trabalhos foram analisados, verificando-se também o critério de inclusão CI1 e os critérios de exclusão CE2

e CE3. Os trabalhos que contemplavam os critérios de inclusão foram adicionados à uma Lista de Selecionados (LS1), enquanto os excluídos foram organizados em uma Lista de Removidos (LR1). Ao final da Etapa II, 57 trabalhos foram selecionados.

Na Etapa III fez-se a leitura da introdução, metodologia e conclusão dos trabalhos inseridos na LS1. Para esta etapa, foram analisados também os critérios de inclusão CI1 e CI4 e o critério de exclusão CE1. Com isso, os estudos excluídos foram inseridos em uma LR2, já os trabalhos que passaram pelos critérios foram adicionados em uma segunda LS2. Com a finalização da etapa III, apenas 12 trabalhos continuaram para a etapa seguinte.

A Etapa IV foi realizada a partir dos trabalhos contidos na LS2. Assim, foi realizada a leitura completa dos trabalhos e uma análise de todos os critérios de inclusão e exclusão. Ao final desta etapa, os trabalhos que cumpriram todos os critérios foram direcionados a responder às QEs. Ao fim dessa etapa, 9 trabalhos foram selecionados. A seleção desses 9 estudos foi baseada nos critérios de seleção para garantir a relevância e qualidade dos dados e atender os objetivos específicos do estudo e minimizar possíveis vieses. Além disso, o processo de seleção dos estudos seguiu o protocolo estabelecido nesta pesquisa para garantir a integridade e qualidade dos resultados.

RESULTADOS E DISCUSSÕES

Nesta seção são apresentados os resultados alcançados com a aplicação do protocolo. Os 9 trabalhos selecionados passaram por uma leitura minuciosa, a fim de examinar os resultados alcançados e as respostas fornecidas às Questões de Pesquisa (QEs). Na Tabela 1 é apresentado um quantitativo de trabalhos retornados em cada fonte de pesquisa, para cada etapa do processo de avaliação.

Tabela 1 – Número de trabalhos retornados nas quatro etapas

Fontes de busca	Etapa I	Etapa II	Etapa III	Etapa IV
IEEE	106	30	8	7
ACM	295	2	0	0
MedLine	66	7	1	1
Scopus	95	13	1	0
Web of Science	53	5	2	1
Total	615	57	12	9

Na Tabela 2 encontram-se detalhados identificadores (IDs) dos trabalhos, autores, ano de publicação e as respostas identificadas a partir das Questões Específicas.

¹ www.dl.acm.org
² <https://ieeexplore.ieee.org/>
³ <https://pubmed.ncbi.nlm.nih.gov/>
⁴ <https://www.scopus.com/>
⁵ <https://login.webofknowledge.com/>

Tabela 2 – Análise detalhada das respostas com a avaliação dos trabalhos

ID	Autores e ano	QE1	QE2	QE3	QE4
1	García-Temza et al. (2019) (10)	Comparação de algoritmos	Python, Biblioteca scikit-learn, Árvore de decisão, Rede Neural, Regressão logística, SVM (Support Vector Machine), Naive Bayes, K-NN	Falta de recursos de diagnósticos, como tomografia computadorizada ou ressonância magnética, principalmente em áreas rurais.	Acurácia, Especificidade, Precisão, Receiver Operating Characteristic (ROC)
2	Hakim et al. (2019) (11)	Comparação de algoritmos	Python, Bagging	Falta de comparação com outros comitês disponíveis na literatura.	Matriz de Confusão, Acurácia, Precisão, F1-Score, Recall, Precision Recall Curve (PRC)
3	Shoily et al. (2019) (12)	Modelo	Software weka, J48, Random Forest, Naive Bayes, K-NN	O conjunto de dados utilizado, foi coletado de várias fontes, o que pode ter contribuído para não ser perfeitamente simétrico, e ter afetado o desempenho do modelo.	Matriz de Confusão, Acurácia, Precisão, F1-Score, Recall
4	Yu et al. (2019) (13)	Modelo	Árvore de decisão	Falta de informações sobre as ferramentas utilizadas para o desenvolvimento e se o sistema é um protótipo ou se já foi desenvolvido.	Acurácia, Precisão, F1-Score, Recall
5	Emon et al. (2020) (14)	Modelo	Python, Biblioteca scikit-learn, Árvore de decisão, Rede Neural, Regressão logística, XGBoost, Naive Bayes, K-NN	Os autores não mencionam se o modelo foi desenvolvido pelos próprios autores ou se foi uma adaptação de um método existente na literatura.	Precisão, Recall
6	Induja e Raji (2019) (15)	Modelo	Árvore de decisão, Naive Bayes, K-NN	Os autores não especificaram quais ferramentas foram utilizadas para o desenvolvimento das soluções, bem como o processo de pré-processamento dos dados.	Matriz de Confusão, Acurácia, Precisão, F1-Score, Recall
7	Fang, Xu e Liu (2020) (16)	Modelo	Random Forest, Extra Trees, Adaboost, K-NN	Os autores não especificaram quais ferramentas foram utilizadas para o desenvolvimento das soluções.	Acurácia, Precisão, F1-Score, Recall
8	Hayashi et al. (2021) (17)	Algoritmo	Python, Biblioteca scikit-learn, Biblioteca pandas, Biblioteca numpy, Biblioteca matplotlib. Regressão logística, Random Forest, SVM, XGBoost, Naive Bayes, K-NN	Devido ao estudo ser multicêntrico, mas conduzido em uma única região do Japão, não ficou claro se o algoritmo teria alto valor preditivo em diferentes áreas com diferentes origens e generalização. Limitações relacionadas à base de dados e ao pré-processamento dos dados.	Acurácia, Especificidade, Precisão, F1-Score, Recall, Receiver Operating Characteristic (ROC)
9	Singh e Choudhary (2017) (18)	Modelo	Árvore de decisão, Rede Neural	O conjunto de dados tinha uma grande quantidade de valores ausentes, com quase 60% das medições ausentes. Devido a isso, fizeram uma redução nos dados de modo que a base de teste ficou com poucas instâncias. As variáveis utilizadas também não são citadas.	Matriz de Confusão, Acurácia

Com relação à questão específica “QE1: Quais as principais soluções?”. Dentre as principais soluções identificadas nos trabalhos selecionados, destacaram-se: 6 trabalhos (ID3, ID4, ID5, ID6, ID7, ID9) desenvolveram modelos a partir de algoritmos de aprendizado de máquina já existentes, 1 trabalho (ID8) desenvolveu um novo algoritmo e 2 trabalhos (ID1, ID2) compararam algoritmos de aprendizado de máquina. Com isso, foi constatado que a maioria das soluções propostas consistiam na criação de modelos utilizando algoritmos de aprendizagem de máquina. Com relação ao conjunto de dados e à forma de coleta, as soluções propostas incluíram:

Em⁽¹⁰⁾ o conjunto de dados utilizado foi coletado a partir de uma central de monitoramento instalada na Unidade de Tratamento de AVC do Hospital Universitário de La Princesa. Essa base de dados coletou dados de 119 pacientes com AVC. O dispositivo registrou informações de março de 2017 a julho de 2017. Em⁽¹¹⁾ o conjunto de dados utilizado inclui informações de 385 pacientes, coletados em cinco hospitais diferentes de Bangladesh. Em⁽¹²⁾ o conjunto de dados utilizado contém 1.058 informações de pacientes e abrange um total de 28 recursos. Essa compilação foi obtida coletando dados de AVC de diversas fontes.

Em⁽¹³⁾ o conjunto de dados utilizado no estudo inclui um total de 287 pacientes com AVC. Os dados foram coletados no centro médico de emergência do *Chungnam National University Hospital* durante o período de 2015 a 2017. Em⁽¹⁴⁾ foram utilizadas informações de um total de 5110 pessoas, abrangendo diversos atributos descritos, como idade, gênero, presença de hipertensão, tipo de trabalho, tipo de residência, histórico de doença cardíaca, nível de glicose, índice de massa corporal (IMC), estado civil, status de fumante e histórico de AVC. Esses dados foram coletados em uma clínica médica de Bangladesh.

Em⁽¹⁵⁾ o conjunto de dados utilizado possui 11.958 registros, incluindo uma combinação de dados de texto não estruturados e estruturados. Os dados hospitalares da vida real, utilizados neste estudo, foram extraídos e armazenados no centro de informações. Em⁽¹⁶⁾ o conjunto de dados utilizado no artigo foi baixado do site do The International Stroke Trial (IST) e consistia em 19.435 dados de pacientes, no entanto, apenas 16.636 pacientes foram usados, por se tratar dos dados relacionados ao subtipo do AVCi. Em⁽¹⁷⁾ o conjunto de dados utilizado consistia em pacientes adultos consecutivos com suspeita de AVC que foram inscritos em um estudo observacional multicêntrico em 12 hospitais no Japão. Inclui 1778 dados de pacientes, destes 332 tinham dados de diagnóstico ausente e 1446 foram analisados. Em⁽¹⁸⁾ o conjunto de dados abrange 5.888 amostras, divididas em 3.228 indivíduos do sexo masculino e 2.660 do sexo feminino. É composto por mais de 600 atributos, abrangendo informações físicas, mentais, sanguíneas e pontuações de diagnóstico médico.

Com relação à questão específica **“QE2: Quais recursos tecnológicos utilizados para o desenvolvimento dessas soluções?”**, nos estudos selecionados alguns autores destacaram quais bibliotecas e pacotes que foram utilizados durante o desenvolvimento das soluções, a citar: Linguagem de programação Python (ID1, ID2, ID5, ID8), Biblioteca scikit-learn (ID1, ID5, ID8), Biblioteca pandas (ID8), Biblioteca numpy (ID8), Biblioteca matplotlib (ID8) e o software weka (ID3). A partir dessa análise pode-se perceber que dos 9 estudos selecionados 4 deles fizeram o uso da linguagem de programação Python, 3 deles fazem uso da biblioteca scikit-learn e pelo menos 1 dos 9 trabalhos selecionados fazem uso das bibliotecas pandas, numpy, matplotlib e do software weka.

Entre as principais técnicas e algoritmos identificados nos trabalhos selecionados, destacaram-se: Árvore de decisão (ID1, ID4, ID5, ID6, ID9), Rede Neural (ID1, ID5, ID9), Regressão logística (ID1, ID5, ID8), Random Forest (ID1, ID3, ID7, ID8), SVM (ID1, ID8), XGBoost (ID5, ID8), Extra Trees (ID7), Adaboost (ID5, ID7), Naive Bayes (ID1, ID3, ID5, ID6, ID7), K-NN (ID1, ID3, ID5, ID6) e o bagging (ID2). Com isso, foi possível perceber que somente técnicas de aprendizagem direcionadas à abordagem supervisionada foram utilizadas.

Dentre as limitações identificadas nos trabalhos com relação à questão específica **“QE3: Quais as limitações identificadas nos trabalhos?”**, várias limitações foram apontadas. Em⁽¹⁰⁾ os autores apontam que identificar o AVC precocemente nem sempre é possível devido à falta de recursos de diagnóstico, como tomografia computadorizada ou ressonância magnética, especialmente em áreas rurais. Em⁽¹¹⁾ a comparação dos resultados ficou restrita a apenas um algoritmo, poderiam ter testado a técnica proposta com outros comitês disponíveis na literatura para identificar se o desempenho da técnica modificada era melhor que o da técnica tradicional do bagging, também, quando comparado com outros modelos.

Em⁽¹²⁾, foram utilizados quatro algoritmos de AM para detectar o tipo de AVC. O conjunto de dados utilizado foi coletado de registros de várias fontes, o que pode ter contribuído para a falta de perfeita simetria. Os autores observaram que isso pode ter afetado o funcionamento do algoritmo Naive Bayes, que, apesar de ter obtido bons resultados, não funcionou como esperado. Em⁽¹³⁾ não foi possível identificar quais ferramentas foram utilizadas para o desenvolvimento e se o sistema é um protótipo ou se já foi desenvolvido, pois é especificada uma arquitetura para o sistema, mas não é explorado e sim feita somente a apresentação do modelo de aprendizagem. Em⁽¹⁴⁾ não foi mencionado se o classificador proposto foi desenvolvido ou se seria uma adaptação de um método existente na literatura. Também não foi esclarecido se ele foi utilizado como uma referência comparativa em relação a outros classificadores base. Em⁽¹⁵⁻¹⁶⁾ não foi especificado quais ferramentas foram utilizadas para o desenvolvimento das soluções. Além disso, em⁽¹⁵⁾ os autores não deixaram claro como foi realizado o processo de pré-processamento dos dados.

Em⁽¹⁷⁾ devido ao estudo ser multicêntrico, mas conduzido em uma única região do Japão, não ficou claro se o algoritmo teria alto valor preditivo em diferentes áreas com origens diversas e generalização. A exclusão de pacientes pediátricos também foi destacada como uma limitação do estudo. Em⁽¹⁸⁾ devido à alta proporção de valores ausentes, representando quase 60% das medições, o conjunto de dados ficou bastante reduzido. Além disso, o estudo não detalhou quais variáveis foram utilizadas, também seria interessante realizar comparações com outros algoritmos existentes na literatura, em vez de restringir a análise comparativa apenas aos algoritmos usados no desenvolvimento da abordagem.

Para a questão específica **“QE4: Como foi realizada a validação dessas soluções?”** os autores utilizaram métricas de avaliação. Entre as principais métricas identificadas nos trabalhos selecionados, destacaram-se: Matriz de Confusão, Acurácia, Especificidade, Precisão, F1-Score, Recall, Receiver Operating Characteristic (ROC) e a Precision Recall Curve (PRC). Na Tabela 4 são apresentadas as métricas utilizadas pelos trabalhos juntamente com um

quantitativo de estudos que as utilizaram. A partir do retorno dessas métricas os autores conseguiram mensurar o desempenho da solução proposta.

CONCLUSÃO

Neste trabalho foi realizada uma Revisão de Escopo com o objetivo de identificar soluções preditivas que fazem o uso de modelos de aprendizado de máquina para ajudar na predição do AVC. Para tal, definiu-se um protocolo para condução da revisão. Com base na avaliação realizada, foi possível identificar quais ferramentas e algoritmos estão sendo utilizados para o desenvolvimento de soluções preditivas. Além disso, foi possível verificar como essas soluções foram validadas e quais são suas principais limitações.

Mediante os resultados foi possível identificar que: i) um conjunto de algoritmos baseados em aprendizagem de máquina vêm sendo utilizados para a criação de modelos, a citar: Random Forest, SVM, Árvores de decisão, K-NN, Naive Bayes, Regressão Logística, XGBoost, Rede Neural, comitês e outros; ii) a linguagem de programação Python, juntamente com suas bibliotecas estão sendo utilizadas com frequência na análise e no desenvolvimento das soluções preditivas; iii) os trabalhos levaram em consideração diversas métricas para validarem suas propostas, a citar: matriz de confusão, acurácia, especificidade, recall, precisão, F1-score e outros, e iv) em todos os estudos os resultados foram pertinentes e podem contribuir para auxiliar no diagnóstico e prevenção do AVC.

REFERÊNCIAS

1. Campbell BCV, Khatri P. Stroke. *The Lancet*; 2020 [Citado 2023 out 3]. Disponível em: [http://dx.doi.org/10.1016/S0140-6736\(20\)31179-X](http://dx.doi.org/10.1016/S0140-6736(20)31179-X).
2. Brasil MSD. Diretrizes de Atenção à Reabilitação da Pessoa com Acidente Vascular Cerebral / Ministério da Saúde, Secretaria de Atenção à Saúde, Departamento de Ações Programáticas Estratégicas. Brasília: Ministério da Saúde; 2013 [Citado 2023 out 3]. Disponível em: https://bvsms.saude.gov.br/bvs/publicacoes/diretrizes_atencao_reabilitacao_acidente_vascular_cerebral.pdf.
3. Meschia JF, Bushnell C, Boden-Albala B, Braun LT, Bravata DM, Chaturvedi S, et al. Guidelines for the Primary Prevention of Stroke: A Statement for Healthcare Professionals from the American Heart Association/American Stroke Association. 2014; 45(12), 3754-3832. [Citado 2023 out 3]. Disponível em: <https://www.ahajournals.org/doi/full/10.1161/STR.0000000000000046>.
4. Tursynova A, Omarov B, Shuketayeva K, Smagul M. 2021, Artificial Intelligence in Stroke Imaging. *International Conference on Cloud Computing, Data Science & Engineering (Confluence)*. 2021 [Citado 2023 out 3]. Disponível em: <https://doi.org/10.1109/Confluence51648.2021.9377102>.
5. Yu J, Park S, Kwon S-H, Ho CMB, Pyo C-S, Lee H. AI-Based Stroke Disease Prediction System Using Real-Time Electromyography Signals. *Applied Sciences*. 2020 [Citado 2023 out 3]. Disponível em: <https://doi.org/10.3390/app10196791>.
6. Oliveira WCGD, Lira AASA, Silva MPS, Leite CRM, Silva JEG. Sistema multi-agente fuzzy para monitoramento e avaliação. In: *Novas Tecnologias Aplicadas a Saúde: Desenvolvimento de Sistemas Dinâmicos: conceitos, aplicações e utilização de técnicas inteligentes e reguladas*. Mossoró: EDUERN; 2019. p.497-523. [Citado 2023 out 3] Disponível em: <https://repositorio.unb.br/handle/10482/37883>.
7. Arksey H, O'Malley L. Scoping studies: towards a methodological framework. *International Journal of Social Research Methodology*. 2005; 8(1), 19–32. [Citado 2023 out 3] Disponível em: <https://doi.org/10.1080/1364557032000119616>.
8. Peters MDJ, Godfrey C, McInerney P, Munn Z, Tricco AC, Khalil H. Capítulo 11. Scoping Reviews. In: Aromataris E, Munn Z. *JBI Manual for Evidence Synthesis*. 2020 [Citado 2023 out 3]. Disponível em: <https://doi.org/10.46658/JBIMES-20-12>.
9. Levac D, Colquhoun H, O'Brien KK. Scoping studies: advancing the methodology. *Implement sci*. 2010; 5(1):5-69.
10. García-Temza L, Risco-Martín JL, Ayala JL, Roselló GR, Camarasaltas JM Comparison of Different Machine Learning Approaches to Model Stroke Subtype Classification and Risk Prediction. *Spring Simulation Conference (SpringSim)*. 2019 [Citado 2023 out 3]. Disponível em: <https://doi.org/10.23919/SpringSim.2019.8732846>.
11. Hakim MA, Hasan MZ, Alam MM, Hasan MM, Huda MM. An Efficient Modified Bagging Method for Early Prediction of Brain Stroke. *International Conference on Computer, Communication, Chemical, Materials and Electronic Engineering (IC4ME2)*. 2019 [Citado 2023 out 3]. Disponível em: <https://doi.org/10.1109/IC4ME247184.2019.9036700>.
12. Shoily TI, Islam T, Jannat, Tanna SA, Alif TM, Ema RR. Detection of Stroke Disease Using Machine Learning Algorithms. *International Conference on Computing, Communication and Networking Technologies (ICCCNT)*. 2019 [Citado 2023 out 3]. Disponível em: <https://doi.org/10.1109/ICCCNT45670.2019.8944689>.
13. Yu J, Kim D, Park H, Chon S, Cho KH, Kim S, et al. Semantic Analysis of NIH Stroke Scale Using Machine Learning Techniques. *International Conference on Platform Technology and Service (PlatCon)*. 2019 [Citado 2023 out 3]. Disponível em: <https://doi.org/10.1109/PlatCon.2019.8668961>.

14. Emon MU, Keya MS, Meghla TI, Rahman MM, Mamun MAS, Kaiser MS. Performance Analysis of Machine Learning Approaches in Stroke Prediction. *International Conference on Electronics, Communication and Aerospace Technology (ICECA)*. 2020 [Citado 2023 out 3]. Disponível em: <https://doi.org/10.1109/ICECA49313.2020.9297525>.
15. Induja SN, Raji CG. Computational Methods for Predicting Chronic Disease in Healthcare Communities. *International Conference on Data Science and Communication (IconDSC)*. 2019 [Citado 2023 out 3]. Disponível em: <https://doi.org/10.1109/IconDSC.2019.8817044>.
16. Fang G, Xu P, Liu W. Automated Ischemic Stroke Subtyping Based on Machine Learning Approach. *IEEE Access*. 2020 [Citado 2023 out 3]. Disponível em: <https://doi.org/10.1109/ACCESS.2020.3004977>.
17. Hayashi Y, Shimada T, Hattori N, Shimazu T, Yoshida Y, Miura RE. A prehospital diagnostic algorithm for strokes using machine learning: a prospective observational study. *Sci Rep*. 2021 [Citado 2023 out 3]. Disponível em: <https://doi.org/10.1038/s41598-021-99828-2>.
18. Singh MS, Choudhary P. Stroke prediction using artificial intelligence. *Annual Industrial Automation and Electromechanical Engineering Conference (IEMECON)*. 2017 [Citado 2023 out 3]. Disponível em: <https://doi.org/10.1109/IEMECON.2017.8079581>.